الاختبار الهجومي والإفصاح المسؤول

أمن الذكاء الاصطناعي، الجامعة، الدرس ٤

في هذا الدرس سوف

- تخطّط لاختبار هجومي بإذن ونطاق وقاعدة للتوقّف.
- تبني تقييمًا: نسب نجاح لكل فئة، وخطورة، واختبارات انحدار.
- تُبلغ وتُفصح بمسؤولية.

تذكّر

- الإذن والنطاق قبل أي اختبار.
- النسبة الإجمالية تُخفي الفئات الضعيفة: أبلغ عن كل فئة.
- المالك أولًا، ثم وقت للإصلاح، ثم الدرس، لا طريقة الاستغلال أبدًا.

قواعد الاشتباك

١. النطاق (٥ دقائق): أي نظام، وأي إصدار، وأي حسابات؟

٢. القواعد (٥ دقائق): بيانات الاختبار، وقاعدة التوقّف، وجهة الاتصال.

٣. البنك (٦ دقائق): عشر حالات خفيفة في ثلاث فئات.

٤. التقرير (٤ دقائق): مسودة قالب الملاحظة.

فقط الأنظمة التي تملكها أو لديك إذن مكتوب باختبارها، وبطلبات خفيفة ومختلقة فقط.

لنتناقش

١. لماذا يحتاج الفريق الأحمر إلى إذن مكتوب؟

٢. ما الذي قد تُخفيه نسبة النجاح الإجمالية؟

٣. لماذا ننشر الدرس ولا ننشر طريقة الاستغلال؟

تحقّق من نفسك

- اكتب السطر الأول من ملاحظة: ما جرّبته، وما تسلّل، ومدى خطورته.