ملاحظات الدرس — لك

هندسة أمن الذكاء الاصطناعي: اختبار الوحدة

أمن الذكاء الاصطناعي، الجامعة، اختبار الوحدة

المدة
٤٥ دقيقة

المواد
ورق وقلم. لا حاجة إلى جهاز.

أهداف التعلّم

- نمذجة التهديدات لتطبيق ذكاء اصطناعي
- قائمة OWASP لأخطر عشرة مخاطر في تطبيقات النماذج اللغوية
- مهاجمة النماذج وتحصينها
- الاختبار الهجومي والإفصاح المسؤول

النشاط: مراجعة التصميم

١. تحصل فرق من ثلاثة على تطبيق ذكاء اصطناعي من الخيال
٢. خمس دقائق: أعلى ثلاثة مخاطر فيه وضوابطها
٣. تبادلوا: يحاول الفريق الآخر كسر خطتكم على الورق
٤. اتفقوا على الإصلاحات، وعلى الاختبار الذي يُثبت كلًّا منها

كل شيء يبقى على الورق ومن الخيال: لا أنظمة حيّة.

للنقاش

- أيّ ممارسة ستستخدمها أولًا في عملك؟
- أيّ سؤال فاجأك، ولماذا؟
- ماذا ستقول لزميل عن اختبار الأنظمة دون إذن؟

تحقّق من نفسك

- أول ممارسة من هذه الوحدة، والمشروع الذي سأستخدمها فيه

جرّبها هذا الأسبوع

اختر من هذه الوحدة الممارسة التي ستستخدمها أولًا في شيء تبنيه (نموذج تهديدات، أو مراجعة وفق قائمة OWASP، أو اختبار متانة، أو أداة تقييم)، واستخدمها هذا الأسبوع.

ورقة عمل

هندسة أمن الذكاء الاصطناعي: اختبار الوحدة

أمن الذكاء الاصطناعي، الجامعة، اختبار الوحدة

الاسم ____ الصف ____ التاريخ ____

١ في نموذج التهديدات لتطبيق مبني على نموذج لغوي، لماذا لا يُعدّ النموذج حدّ ثقة؟

◯ كل ما في سياقه قد يوجّه ما يقوله والأدوات التي يستدعيها ◯ إنه أبطأ من أن يفحص مدخلاته

◯ إنه يعمل على حاسوب شخص آخر

٢ صِل كل خطر من قائمة OWASP بمثال عليه.

LLM03 سلسلة التوريد	مرجع مختلق ينتهي في مقال
LLM05 التعامل غير السليم مع المخرجات	تُقرأ تعليماته وفيها كلمة مرور
LLM07 تسريب تعليمات النظام	ردّ يُلصق في صفحة فيعمل سكريبتًا
LLM09 المعلومات المضلّلة	ملف نموذج شبيه فيه باب خلفي

٣ ماذا يطبع هذا البرنامج؟

```
flows = [("model", "email"), ("web", "model")]
reach = {"web"}
for a, b in flows:
    if a in reach:
        reach.add(b)
print("email" in reach)
```

◯ True ◯ False ◯ web

٤ يكفي أن تقول للنموذج «لا تكشف كلمة المرور أبدًا» لتبقى كلمة مرور في تعليمات نظامه آمنة.

◯ صح ◯ خطأ

٥ نموذج خطي وزناه ٣ وسالب ٢. ماذا يطبع هذا البرنامج؟

```
w, x, eps = [3, -2], [2, 1], 0.5
s = sum(a * c for a, c in zip(w, x))
drop = eps * sum(abs(a) for a in w)
print(s, s - drop)
```

◯ 1.5 4 ◯ 6.5 4 ◯ 3.5 4