ملاحظات المراجعة — لك

هندسة أمن الذكاء الاصطناعي: اختبار الوحدة

أمن الذكاء الاصطناعي، الجامعة، اختبار الوحدة

المواد

ورق وقلم. لا حاجة إلى جهاز.

أهداف التعلّم

- نمذجة التهديدات لتطبيق ذكاء اصطناعي
- قائمة OWASP لأخطر عشرة مخاطر في تطبيقات النماذج اللغوية
- مهاجمة النماذج وتحصينها
- الاختبار الهجومي والإفصاح المسؤول

النشاط: مراجعة التصميم

١. تحصل فرق من ثلاثة على تطبيق ذكاء اصطناعي من الخيال
٢. خمس دقائق: أعلى ثلاثة مخاطر فيه وإجراءاتها الوقائية
٣. تبادلوا: يحاول الفريق الآخر كسر خطتكم على الورق
٤. اتفقوا على الإصلاحات، وعلى الاختبار الذي يُثبت كلًّا منها

كل شيء يبقى على الورق ومن الخيال: لا أنظمة حيّة.

للنقاش

- أيّ ممارسة ستستخدمها أولًا في عملك؟
- أيّ سؤال فاجأك، ولماذا؟
- ماذا ستقول لزميل عن اختبار الأنظمة دون إذن؟

تحقّق من نفسك

- أول ممارسة من هذه الوحدة، والمشروع الذي سأستخدمها فيه

جرّبها هذا الأسبوع

اختر من هذه الوحدة الممارسة التي ستستخدمها أولًا في شيء تبنيه (نموذج تهديدات، أو مراجعة وفق قائمة OWASP، أو اختبار متانة، أو أداة تقييم)، واستخدمها هذا الأسبوع.

ورقة الاختبار

هندسة أمن الذكاء الاصطناعي: اختبار الوحدة

أمن الذكاء الاصطناعي، الجامعة، اختبار الوحدة

الاسم _____ الفصل _____ التاريخ _____

١ في نموذج التهديدات لتطبيق مبني على نموذج لغوي، لماذا لا يُعدّ النموذج حدّ ثقة؟

◯ إنه يعمل على حاسوب شخص آخر ◯ كل ما في سياقه قد يوجّه ما يقوله والأدوات التي يستدعيها

◯ إنه أبطأ من أن يفحص مدخلاته

٢ صِل كل خطر من قائمة OWASP بمثال عليه.

LLM03 سلسلة التوريد	تُقرأ تعليماته وفيها كلمة مرور
LLM05 التعامل غير السليم مع المخرجات	ملف نموذج شبيه فيه باب خلفي
LLM07 تسريب تعليمات النظام	مرجع مختلق ينتهي في مقال
LLM09 المعلومات المضلّلة	ردّ يُلصق في صفحة فيعمل سكريبتًا

٣ ماذا يطبع هذا البرنامج؟

```
flows = [("model", "email"),
         ("web", "model")]
reach = {"web"}
for a, b in flows:
    if a in reach:
        reach.add(b)
print("email" in reach)
```

◯ False ◯ True ◯ web

٤ يكفي أن تقول للنموذج «لا تكشف كلمة المرور أبدًا» لتبقى كلمة مرور في تعليمات نظامه آمنة.

◯ صح ◯ خطأ

٥ نموذج خطي وزناه ٣ وسالب ٢. ماذا يطبع هذا البرنامج؟

```
w, x, eps = [3, -2], [2, 1], 0.5
s = sum(a * c for a, c in zip(w, x))
drop = eps * sum(abs(a) for a in w)
print(s, s - drop)
```

◯ 4 1.5 ◯ 4 3.5 ◯ 4 6.5

٦ أيّ التغييرات تجعل نسخ نموذج باستعلامه أصعب؟ اختر كل ما ينطبق.

☐ حدود للطلبات لكل مستخدم ☐ إرجاع التسميات لا الدرجات الدقيقة ☐ نشر أوزان النموذج

☐ مراقبة أنماط الاستعلام غير المعتادة

٧ **ماذا يحاول هجوم استدلال العضوية أن يعرف؟**

○ كلمة مرور النموذج ○ هل كان سجلّ شخص ما ضمن بيانات التدريب ○ أيّ المستخدمين متّصلون الآن

٨ **وجدت ثغرة في نظام ذكاء اصطناعي لغيرك. رتّب الخطوات المسؤولة.**

☐ تحقّق من الإصلاح معه

☐ انشر الدرس، دون طريقة الاستغلال

☐ توقّف، ولا تستخدمها مرة أخرى

☐ امنحه وقتًا لإصلاحها

☐ أبلغ المالك بها سرًّا

٩ **بعد إصلاح ملاحظة واحدة، عليك أن تعيد تشغيل بنك الاختبارات كله، لا تلك الحالة وحدها.**

○ صح ○ خطأ

١٠ **أكمل قاعدتي التصميم.**

عامل مخرجات النموذج بوصفها مدخلات _____ ، وأعطِ الوكيل _____ الأدوات التي تحتاج إليها مهمته.

بنك الكلمات: أقل، أكثر، غير موثوقة، موثوقة

تحقّق من إجاباتك

هندسة أمن الذكاء الاصطناعي: اختبار الوحدة

أمن الذكاء الاصطناعي، الجامعة، اختبار الوحدة

١ **كل ما في سياقه قد يوجّه ما يقوله والأدوات التي يستدعيها**

التعليمات المخبّأة في صفحة أو ملف أو رسالة تصل كلها إلى النموذج نصًّا، وقد يتبعها.

٢ **LLM03 سلسلة التوريد — ملف نموذج شبيه فيه باب خلفي**
LLM05 التعامل غير السليم مع المخرجات — ردّ يُلصق في صفحة فيعمل سكريبتًا
LLM07 تسريب تعليمات النظام — تُقرأ تعليماته وفيها كلمة مرور
LLM09 المعلومات المضلّلة — مرجع مختلق ينتهي في مقال

المكوّنات المزيّفة، والمخرجات غير المفحوصة، والأسرار في التعليمات، والأخطاء الواثقة أربعة مخاطر مختلفة، لكلٍّ منها إجراؤه الوقائي: التحقّق، والترميز، وإبقاء الأسرار في الكود، وتدقيق المعلومات.

٣ **False**

ترى الحلقة ("model", "email") أولًا، حين لم يُبلَغ model بعد، ثم تضيف model.

٤ **خطأ**

افترض أن تعليمات النظام ستُقرأ. فمكان الأسرار كود التطبيق أو خزنته، ومكان قرارات الوصول الكود، لا التعليمات الموجّهة إلى النموذج وحدها.

٥ **4 1.5**

الدرجة ٣ × ٢ ثم سالب ٢ × ١، أي ٤. وأسوأ دفع بحجم ٠٫٥ يخفضها بمقدار ٠٫٥ × (٣ + ٢) = ٢٫٥، إلى ١٫٥: وما زالت موجبة، فلا يمكن أن تنقلب الإجابة عند هذه الميزانية.

٦ **إرجاع التسميات لا الدرجات الدقيقة، حدود للطلبات لكل مستخدم، مراقبة أنماط الاستعلام غير المعتادة**

يحتاج الاستخراج إلى إجابات كثيرة بأكبر قدر من التفاصيل: والتسمية وحدها، والحدود، والمراقبة تحرمه من ذلك.

٧ **هل كان سجلّ شخص ما ضمن بيانات التدريب**

تكون النماذج غالبًا أكثر ثقة في الأمثلة التي تدرّبت عليها، فيستطيع المهاجم تخمين هل استُخدم سجلّ شخص ما، وهذا وحده قد يكشف أمرًا خاصًا، ككونه مريضًا في عيادة.

٨ **من الأعلى إلى الأسفل: ٤، ٥، ١، ٣، ٢**

التوقّف يحمي المستخدمين الحقيقيين، والمالك يعرف أولًا ويُمنح وقتًا للإصلاح، ولا يُنشر الدرس إلا بعد ذلك، ولا يُنشر أبدًا طريقةَ استغلال عاملة.

٩ **صح**

الإصلاحات تكسر أشياء أخرى. وإعادة تشغيل كل شيء، مع الاحتفاظ بالحالة المُصلَحة اختبارَ انحدار، تُظهر أن الإصلاح نجح وأن شيئًا آخر لم يسُؤ.

١٠ **عامل مخرجات النموذج بوصفها مدخلات غير موثوقة، وأعطِ الوكيل أقل الأدوات التي تحتاج إليها مهمته.**

قد تحمل مخرجات النموذج أي شيء كان في سياقه، فرمّزها وافحصها كأي مدخلات من مستخدم.