هندسة أمن الذكاء الاصطناعي: مراجعة

أمن الذكاء الاصطناعي، الجامعة، اختبار الوحدة

في هذه الوحدة

- نمذجة التهديدات لتطبيق ذكاء اصطناعي
- قائمة OWASP لأخطر عشرة مخاطر في تطبيقات النماذج اللغوية
- مهاجمة النماذج وتحصينها
- الاختبار الهجومي والإفصاح المسؤول

الأفكار الكبرى

- نموذج التهديدات أولًا: المسارات، والحدود، وSTRIDE، والطرق إلى الأفعال
- قائمة OWASP: ما يدخل، وما يخرج، والنظام؛ ومخرجات النموذج مدخلات غير موثوقة
- الثقة ليست متانة، ولكل دفاع ثمن
- الإذن، ونسبة نجاح لكل فئة، والمالك يعرف أولًا

مراجعة التصميم

١. تحصل فرق من ثلاثة على تطبيق ذكاء اصطناعي من الخيال
٢. خمس دقائق: أعلى ثلاثة مخاطر فيه وإجراءاتها الوقائية
٣. تبادلوا: يحاول الفريق الآخر كسر خطتكم على الورق
٤. اتفقوا على الإصلاحات، وعلى الاختبار الذي يُثبت كلًّا منها

كل شيء يبقى على الورق ومن الخيال: لا أنظمة حيّة.

لنتناقش

١. أيّ ممارسة ستستخدمها أولًا في عملك؟

٢. أيّ سؤال فاجأك، ولماذا؟

٣. ماذا ستقول لزميل عن اختبار الأنظمة دون إذن؟

تحقّق من نفسك

- أول ممارسة من هذه الوحدة، والمشروع الذي سأستخدمها فيه