خطة المحاضرة، لعضو هيئة التدريس

الأمثلة العدائية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ١

المدة
٦٠ دقيقة

المواد
جهاز عرض أو سبّورة، شرائح المحاضرة وورقة الحلقة النقاشية من الحزمة، هواتف أو حواسيب فيها دَرسي، للمعمل

أهداف التعلّم

- نفسّر سبب وجود الأمثلة العدائية.
- نحسب FGSM ونشغّلها.
- نقيّم الدفاعات بأمانة.

النشاط: هاجم ودافع وهاجم مجددًا

١. التمهيد (٥ دقائق): اعرض علامة الوقوف ذات الملصقات واسأل ماذا يقرأ المصنّف.

٢. الهجوم (١٥ دقيقة): يحسب كل زوجين $\varepsilon \|w\|_1$ لمصنّف ورقي ويقلبان توقعه.

٣. الدفاع (١٥ دقيقة): يقترح كل زوجين دفاعًا ويحددان نموذج تهديده.

٤. الكسر (٢٠ دقيقة): تبادلوا وصمّموا هجومًا يعرف دفاع الزوج الآخر.

٥. الختام (٥ دقائق): يكتب الطلاب أكثر نقطة غامضة في المحاضرة وسؤالًا واحدًا، واقرأها قبل الأسبوع القادم.

للنقاش

- أيّ الدفاعات صمدت؟
- ماذا أغفل نموذج التهديد؟
- كيف ستعرض المتانة؟

بطاقة الخروج

- سمِّ ادعاءً لن تقبله بعد الآن دون هجوم متكيّف.

جرّبها في محاضرتك القادمة

أعطِ كل زوجين مصنّفًا خطيًا بثلاث خصائص على الورق، يهاجمه أحدهما بـ $\varepsilon = 0.1$ ويقترح الآخر دفاعًا، ثم يتبادلان ويهاجمان الدفاع.

ورقة الحلقة النقاشية، للطلاب

الأمثلة العدائية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ١

الاسم _____ الصف _____ التاريخ _____

١ دفاع يوقف FGSM. ما الاختبار التالي؟

○ تشغيل FGSM مرة أخرى ببذرة جديدة ○ هجوم متكيّف مصمَّم للدفاع ○ عرض الدقة على البيانات النظيفة فقط

٢ احسب حد التغيير.

لنموذج خطي $w = (1, -2, 4)$. $\sum |w_i|$ = _____ ، فمع $\varepsilon = 0.05$ يمكن أن تغيّر FGSM الدرجة بمقدار _____ .

بنك الكلمات: 7، 3، 0.15، 0.35

٣ أيّها ينتمي إلى تقييم متانة سليم؟ اختر كل ما ينطبق.

☐ نموذج تهديد وε محددان ☐ هجوم متكيّف مصمَّم للدفاع ☐ هجمات تكرارية مثل PGD لا FGSM فقط

☐ عرض الدقة النظيفة فقط

٤ إذا فشلت FGSM أمام دفاع، فالنموذج متين ضمن تلك ε.

○ صح ○ خطأ

٥ طابق كل فكرة مع مصدرها.

الخطية تفسّر الأمثلة العدائية	• • • •	Eykholt وآخرون، ٢٠١٨
التدريب العدائي تصغير وتعظيم	• • • •	Athalye وآخرون، ٢٠١٨
التدرجات المموَّهة تكسر الدفاعات	• • • •	Madry وآخرون، ٢٠١٨
ملصقات مادية على علامات الوقوف	• • • •	Goodfellow وآخرون، ٢٠١٥

حين يدّعي طلابك أن نموذجًا آمن، ما الدليل الذي تقبله حاليًا؟