الأمثلة العدائية

المدة
٦٠ دقيقة

المواد
جهاز عرض أو سبّورة، شرائح المحاضرة وورقة الحلقة النقاشية من الحزمة، هواتف أو حواسيب فيها «درسي»، للمختبر

أهداف التعلّم

- نفسّر سبب وجود الأمثلة العدائية.
- نحسب FGSM ونشغّلها.
- نقيّم الدفاعات بأمانة.

النشاط: هاجم ودافع وهاجم مجددًا

١. التمهيد (٥ دقائق): اعرض علامة الوقوف ذات الملصقات واسأل ماذا يقرأ المصنّف.
٢. الهجوم (١٥ دقيقة): يحسب كل زوجين $\varepsilon \|w\|_1$ لمصنّف ورقي ويقلبان توقعه.
٣. الدفاع (١٥ دقيقة): يقترح كل زوجين دفاعًا ويحددان نموذج تهديده.
٤. الكسر (٢٠ دقيقة): تبادلوا وصمّموا هجومًا يعرف دفاع الزوج الآخر.
٥. الختام (٥ دقائق): يكتب الطلاب أكثر نقطة غامضة في المحاضرة وسؤالًا واحدًا، واقرأها قبل الأسبوع القادم.

للنقاش

- أيّ الدفاعات صمدت؟
- ماذا أغفل نموذج التهديد؟
- كيف ستعرض المتانة؟

بطاقة الخروج

- سمِّ ادعاءً لن تقبله بعد الآن دون هجوم متكيّف.

جرّبها في محاضرتك القادمة

أعطِ كل زوجين مصنّفًا خطيًا بثلاث خصائص على الورق، يهاجمه أحدهما بـ $\varepsilon = 0.1$ ويقترح الآخر دفاعًا، ثم يتبادلان ويهاجمان الدفاع.

ورقة الحلقة النقاشية، للطلاب

الأمثلة العدائية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ١

الاسم _____ المجموعة _____ التاريخ _____

١ دفاع يوقف FGSM. ما الاختبار التالي؟

○ تشغيل FGSM مرة أخرى ببذرة جديدة ○ هجوم متكيّف مصمَّم للدفاع ○ عرض الدقة على البيانات النظيفة فقط

٢ احسب حد التغيير.

لنموذج خطي $w = (1, -2, 4)$. $\Sigma|w_i| =$ _____ ، فمع $\varepsilon = 0.05$ يمكن أن تغيّر FGSM الدرجة بمقدار _____ .

بنك الكلمات: 0.15، 0.35، 7، 3

٣ أيّها ينتمي إلى تقييم متانة سليم؟ اختر كل ما ينطبق.

☐ هجمات تكرارية مثل PGD لا FGSM فقط ☐ نموذج تهديد وε محددان ☐ عرض الدقة النظيفة فقط

☐ هجوم متكيّف مصمَّم للدفاع

٤ الدفاع الذي يصدّ FGSM قد يسقط مع ذلك أمام هجوم متكيّف ضمن ε نفسها.

○ صح ○ خطأ

٥ طابق كل فكرة مع مصدرها.

الخطية تفسّر الأمثلة العدائية	• • • •	Madry وآخرون، ٢٠١٨
التدريب العدائي تصغير وتعظيم	• • • •	Goodfellow وآخرون، ٢٠١٥
التدرجات المموَّهة تكسر الدفاعات	• • • •	Eykholt وآخرون، ٢٠١٨
ملصقات مادية على علامات الوقوف	• • • •	Athalye وآخرون، ٢٠١٨

الإجابات، لعضو هيئة التدريس

الأمثلة العدائية

١ **هجوم متكيّف مصمَّم للدفاع**

لا يختبر الدفاعَ بعدل إلا هجومٌ يعرفه.

٢ **لنموذج خطي $w = (1, -2, 4)$. $\|w\|_1 = 7$، فمع $\varepsilon = 0.05$ يمكن أن تغيّر FGSM الدرجة بمقدار 0.35.**

تُجمع القيم المطلقة: $1 + 2 + 4 = 7$، و$7 \times 0.05 = 0.35$.

٣ **نموذج تهديد وε محددان، هجوم متكيّف مصمَّم للدفاع، هجمات تكرارية مثل PGD لا FGSM فقط**

الدقة النظيفة لا تقول شيئًا عن المتانة.

٤ **صح**

الهجمات الضعيفة تعطي ثقة زائفة، وقد سقطت دفاعات كثيرة كهذه أمام هجمات متكيّفة.

٥ **الخطية تفسّر الأمثلة العدائية — Goodfellow وآخرون، ٢٠١٥**
التدريب العدائي تصغير وتعظيم — Madry وآخرون، ٢٠١٨
التدرجات المموَّهة تكسر الدفاعات — Athalye وآخرون، ٢٠١٨
ملصقات مادية على علامات الوقوف — Eykholt وآخرون، ٢٠١٨

كل ورقة قراءة معيارية في الموضوع.

لتفكّر فيه

حين يدّعي طلابك أن نموذجًا آمن، ما الدليل الذي تقبله حاليًا؟