الأمثلة العدائية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ١

في هذه المحاضرة

- نفسّر سبب وجود الأمثلة العدائية.
- نحسب FGSM ونشغّلها.
- نقيّم الدفاعات بأمانة.

تذكّر

- التغييرات الصغيرة تتراكم.
- درّب على الهجمات.
- هاجم الدفاع.

هاجم ودافع وهاجم مجددًا

١. التمهيد (٥ دقائق): Show the stop sign with stickers and ask what the classifier reads.

٢. الهجوم (١٥ دقيقة): يدويًا.

٣. الدفاع (١٥ دقيقة): اقترح.

٤. الكسر (٢٠ دقيقة): تكيّف.

٥. الختام (٥ دقائق): ورقة الدقيقة الواحدة.

لنتناقش

١. أيّ الدفاعات صمدت؟

٢. ماذا أغفل نموذج التهديد؟

٣. كيف ستعرض المتانة؟

بطاقة الخروج

- سمِّ ادعاءً لن تقبله بعد الآن دون هجوم متكيّف.