خطة المحاضرة، لعضو هيئة التدريس

تسميم البيانات والأبواب الخلفية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ٢

المدة
٦٠ دقيقة

المواد
جهاز عرض أو سبّورة، شرائح المحاضرة وورقة الحلقة النقاشية من الحزمة، هواتف أو حواسيب فيها دَرسي، للمعمل

أهداف التعلّم

- نصنّف هجمات التسميم.
- نفسّر الأبواب الخلفية.
- نحمي سلسلة إمداد البيانات.

النشاط: ارسم سلسلة الإمداد

١. التمهيد (٥ دقائق): احكِ قصة Tay واسأل كيف تغيّر النموذج دون المساس بكوده.

٢. الرسم (١٥ دقيقة): ترسم المجموعات سلسلة إمداد بيانات فلتر البريد المزعج من البلاغات إلى إعادة التدريب.

٣. الهجوم (١٥ دقيقة): حدّد أين يمكن للمهاجم إدخال البيانات وأيّ هدف يخدمه كل منها.

٤. الضبط (٢٠ دقيقة): اقترح ضابطًا لكل نقطة دخول وقل ما لا يستطيع منعه.

٥. الختام (٥ دقائق): يكتب الطلاب أكثر نقطة غامضة في المحاضرة وسؤالًا واحدًا، واقرأها قبل الأسبوع القادم.

للنقاش

- أيّ نقطة دخول كانت الأسهل؟
- هل تكشفها الدقة النظيفة؟
- أيّ ضابط يغطي أكثر؟

بطاقة الخروج

- سمِّ مجموعة بيانات تستخدمها ولا تستطيع التحقق من مصدرها.

جرّبها في محاضرتك القادمة

أعطِ المجموعات فلتر بريد مزعج يُعاد تدريبه أسبوعيًا على بلاغات المستخدمين، لتحدد كل مجموعة كل نقطة يمكن للمهاجم إدخال بيانات منها وتقترح ضابطًا لكل منها.

ورقة الحلقة النقاشية، للطلاب

تسميم البيانات والأبواب الخلفية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ٢

الاسم _____ الصف _____ التاريخ _____

١ التدريب على صور مجمّعة من الويب. أيّ خطوة تحمي على نحو أفضل من التسميم؟

○ نموذج أكبر ○ صور مجمّعة أكثر ○ تتبّع المصدر والتصفية ومجموعة اختبار موثوقة

٢ قدّر حجم الهجوم.

مجموعة بيانات فيها 20,000 صورة. تسميم 1% يعني _____ صورة، وتسميم 0.5% يعني _____.

بنك الكلمات: 200، 2000، 20، 100

٣ أيّها يساعد في حماية نموذج مدرَّب على بيانات مجمّعة؟ اختر كل ما ينطبق.

☐ تسجيل مصدر البيانات والتحقق منه ☐ التصفية بالقيم الشاذة والبصمات الطيفية

☐ مجموعة اختبار موثوقة منفصلة ☐ الاعتماد على الدقة النظيفة العالية

٤ النموذج ذو الدقة النظيفة 98% لا يمكن أن يحتوي بابًا خلفيًا.

○ صح ○ خطأ

٥ طابق كل هجوم مع أثره.

تسميم الإتاحة	• • • •	مدخل مصنوع وقت الاختبار
التسميم الموجّه	• • • •	فشل عند ظهور محفّز فقط
الباب الخلفي	• • • •	فشل في مدخلات مختارة
التهرّب	• • • •	دقة أقل على كل المدخلات

✎ من أين تأتي مجموعات البيانات في مقررك، وهل سأل طالب يومًا إن كانت موثوقة؟