خطة المحاضرة، لعضو هيئة التدريس

تسميم البيانات والأبواب الخلفية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ٢

المدة
٦٠ دقيقة

المواد
جهاز عرض أو سبّورة، شرائح المحاضرة وورقة الحلقة النقاشية من الحزمة، هواتف أو حواسيب فيها «درسي»، للمختبر

أهداف التعلّم

- نصنّف هجمات التسميم.
- نفسّر الأبواب الخلفية.
- نحمي سلسلة توريد البيانات.

النشاط: ارسم سلسلة التوريد

١. التمهيد (٥ دقائق): احكِ قصة Tay واسأل كيف تغيّر النموذج دون المساس بكوده.
٢. الرسم (١٥ دقيقة): ترسم المجموعات سلسلة توريد بيانات فلتر البريد المزعج من البلاغات إلى إعادة التدريب.
٣. الهجوم (١٥ دقيقة): حدّد أين يمكن للمهاجم إدخال البيانات وأيّ هدف يخدمه كل منها.
٤. الضبط (٢٠ دقيقة): اقترح ضابطًا لكل نقطة دخول وقل ما لا يستطيع منعه.
٥. الختام (٥ دقائق): يكتب الطلاب أكثر نقطة غامضة في المحاضرة وسؤالًا واحدًا، واقرأها قبل الأسبوع القادم.

للنقاش

- أيّ نقطة دخول كانت الأسهل؟
- هل تكشفها الدقة النظيفة؟
- أيّ ضابط يغطي أكثر؟

بطاقة الخروج

- سمِّ مجموعة بيانات تستخدمها ولا تستطيع التحقق من مصدرها.

جرّبها في محاضرتك القادمة

أعطِ المجموعات فلتر بريد مزعج يُعاد تدريبه أسبوعيًا على بلاغات المستخدمين، لتحدد كل مجموعة كل نقطة يمكن للمهاجم إدخال بيانات منها وتقترح إجراءً وقائيًا لكل منها.

ورقة الحلقة النقاشية، للطلاب

تسميم البيانات والأبواب الخلفية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ٢

الاسم _____ المجموعة _____ التاريخ _____

١ التدريب على صور مجمّعة من الويب. أيّ خطوة تحمي على نحو أفضل من التسميم؟

○ صور مجمّعة أكثر ○ تتبّع المصدر والتصفية ومجموعة اختبار موثوقة ○ نموذج أكبر

٢ قدّر حجم الهجوم.

مجموعة بيانات فيها 20,000 صورة. تسميم 1% يعني _____ صورة، وتسميم 0.5% يعني _____.

بنك الكلمات: 20، 100، 200، 2000

٣ أيّها يساعد في حماية نموذج مدرَّب على بيانات مجمّعة؟ اختر كل ما ينطبق.

☐ تسجيل مصدر البيانات والتحقق منه ☐ الاعتماد على الدقة النظيفة العالية ☐ مجموعة اختبار موثوقة منفصلة

☐ التصفية بالقيم الشاذة والبصمات الطيفية

٤ النموذج ذو الدقة النظيفة 98% لا يمكن أن يحتوي بابًا خلفيًا.

○ صح ○ خطأ

٥ طابق كل هجوم مع أثره.

تسميم الإتاحة	• • • •	فشل عند ظهور محفّز فقط
التسميم الموجّه	• • • •	مدخل مصنوع وقت الاختبار
الباب الخلفي	• • • •	دقة أقل على كل المدخلات
التهرّب	• • • •	فشل في مدخلات مختارة

الإجابات، لعضو هيئة التدريس

تسميم البيانات والأبواب الخلفية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ٢

١ **تتبّع المصدر والتصفية ومجموعة اختبار موثوقة**

تحكّم فيما يدخل البيانات وراجعه.

٢ **مجموعة بيانات فيها 20,000 صورة. تسميم 1% يعني 200 صورة، وتسميم 0.5% يعني 100.**

200 = 20,000 × 0.01 و100 = 20,000 × 0.005: يحتاج الباب الخلفي صفوفًا قليلة جدًا.

٣ **تسجيل مصدر البيانات والتحقق منه، التصفية بالقيم الشاذة والبصمات الطيفية، مجموعة اختبار موثوقة منفصلة**

تحتفظ النماذج ذات الأبواب الخلفية بدقة نظيفة عالية.

٤ **خطأ**

تُصمَّم الأبواب الخلفية لتترك الدقة النظيفة دون تغيير.

٥ **تسميم الإتاحة — دقة أقل على كل المدخلات**
التسميم الموجّه — فشل في مدخلات مختارة
الباب الخلفي — فشل عند ظهور محفّز فقط
التهرّب — مدخل مصنوع وقت الاختبار

يعمل التسميم في التدريب، ويعمل التهرّب وقت الاختبار.

✎ **لتفكّر فيه**

من أين تأتي مجموعات البيانات في مقررك، وهل سأل طالب يومًا إن كانت موثوقة؟