تسميم البيانات والأبواب الخلفية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ٢

في هذه المحاضرة

- نصنّف هجمات التسميم.
- نفسّر الأبواب الخلفية.
- نحمي سلسلة إمداد البيانات.

تذكّر

- البيانات سطح هجوم.
- الدقة النظيفة تخفي الأبواب الخلفية.
- تتبّع المصدر.

ارسم سلسلة الإمداد

١. التمهيد (٥ دقائق): Tell the Tay story and ask how the model was changed without touching its code.

٢. الرسم (١٥ دقيقة): المصادر.

٣. الهجوم (١٥ دقيقة): نقاط الدخول.

٤. الضبط (٢٠ دقيقة): الدفاعات.

٥. الختام (٥ دقائق): ورقة الدقيقة الواحدة.

لنتناقش

١. أيّ نقطة دخول كانت الأسهل؟

٢. هل تكشفها الدقة النظيفة؟

٣. أيّ ضابط يغطي أكثر؟

بطاقة الخروج

- سمِّ مجموعة بيانات تستخدمها ولا تستطيع التحقق من مصدرها.