خطة المحاضرة، لعضو هيئة التدريس

هجمات الخصوصية والخصوصية التفاضلية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ٣

المدة
٦٠ دقيقة

المواد
جهاز عرض أو سبّورة، شرائح المحاضرة وورقة الحلقة النقاشية من الحزمة، هواتف أو حواسيب فيها «درسي»، للمختبر

أهداف التعلّم

- نفسّر استنتاج العضوية.
- نعرّف الخصوصية التفاضلية.
- نعاير الضوضاء.

النشاط: أجب عشوائيًا

١. التمهيد (٥ دقائق): اعرض التقييمات المجرّدة من الهوية واسأل كيف يمكن التعرّف على شخص.

٢. الرمي (١٠ دقائق): يجيب الطلاب عن سؤال حساس بالاستجابة العشوائية.

٣. التقدير (١٥ دقيقة): استعد النسبة الحقيقية من الإجابات المشوّشة.

٤. المعايرة (٢٥ دقيقة): احسب مقاييس لابلاس لعدة قيم ε وقارن الأعداد المنشورة.

٥. الختام (٥ دقائق): يكتب الطلاب أكثر نقطة غامضة في المحاضرة وسؤالًا واحدًا، واقرأها قبل الأسبوع القادم.

للنقاش

- لماذا لا يمكن محاسبة أحد على إجابة؟
- ماذا تكلّف ε؟
- من يحدد الميزانية؟

بطاقة الخروج

- أيّ إصدار بيانات في مؤسستك ستحميه بالخصوصية التفاضلية؟

جرّبها في محاضرتك القادمة

اسأل الطلاب سؤالًا حساسًا جوابه نعم أو لا بطريقة الاستجابة العشوائية مع رمي عملة أولًا، ثم قدّروا النسبة الحقيقية معًا وناقشوا لماذا لا تكشف أي إجابة منفردة أحدًا.

ورقة الحلقة النقاشية، للطلاب

هجمات الخصوصية والخصوصية التفاضلية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ٣

الاسم _____ المجموعة _____ التاريخ _____

١ أيّ خطوة تعطي حدًا مثبتًا لتسريب العضوية؟

○ حذف الأسماء ○ التدريب بخصوصية تفاضلية ○ الإيقاف المبكر

٢ اضبط الضوضاء.

حساسية العدّ 1. يكون مقياس لابلاس _____ عند ε = 0.1 و _____ عند ε = 1.

بنك الكلمات: 0.1، 1، 10، 100

٣ أيّ العبارات عن استنتاج العضوية صحيحة؟ اختر كل ما ينطبق.

☐ حذف الأسماء من بيانات التدريب يمنعه ☐ تحدّ الخصوصية التفاضلية أفضلية الهجوم

☐ الفجوة الأكبر بين التدريب والاختبار تساعد المهاجم عادة ☐ يمكن لنماذج الظل محاكاة الهدف

٤ الإجابة عن استعلامين، كل منهما بـ ε = 0.5، تعطي خسارة خصوصية كلية لا تتجاوز ε = 1.

○ صح ○ خطأ

٥ رتّب خطوة واحدة من DP-SGD.

☐ قص كلًا منها إلى المعيار C

☐ حدّث واحسب ε

☐ احسب تدرج كل مثال

☐ أضف ضوضاء غاوسية إلى المجموع

الإجابات، لعضو هيئة التدريس

هجمات الخصوصية والخصوصية التفاضلية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ٣

١ **التدريب بخصوصية تفاضلية**

يحدّ تأثير كل شخص.

٢ **حساسية العدّ 1. يكون مقياس لابلاس 10 عند ε = 0.1 و1 عند ε = 1.**

المقياس = Δ/ε: 1/0.1 = 10 و1/1 = 1. ε الأصغر تعني ضوضاء أكثر وخصوصية أكبر.

٣ **الفجوة الأكبر بين التدريب والاختبار تساعد المهاجم عادة، يمكن لنماذج الظل محاكاة الهدف، تحدّ الخصوصية التفاضلية أفضلية الهجوم**

يسرّب النموذج عبر سلوكه لا عبر الأسماء.

٤ **صح**

التركيب الأساسي: تُجمع خسائر الخصوصية.

٥ **من الأعلى إلى الأسفل: ٢، ٤، ١، ٣**

يحدّ القص الحساسية لكي تُعايَر الضوضاء.

✎ **لتفكّر فيه**

كيف يتعلّم طلابك حاليًا أن حذف الأسماء لا يكفي؟