خطة المحاضرة، لعضو هيئة التدريس

حقن التعليمات وتطبيقات النماذج اللغوية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ٤

المدة
٦٠ دقيقة

المواد
جهاز عرض أو سبّورة، شرائح المحاضرة وورقة الحلقة النقاشية من الحزمة، هواتف أو حواسيب فيها «درسي»، للمختبر

أهداف التعلّم

- نفسّر حقن التعليمات.
- نصمّم دفاعًا متعدد الطبقات.
- ننفّذ الاختبار الهجومي بأمان.

النشاط: فريق أحمر ضمن النطاق

١. التمهيد (٥ دقائق): اعرض التعليمات المخفية في البريد واسأل ماذا سيفعل المساعد.

٢. النطاق (١٠ دقائق): اقرؤوا النطاق وقواعد الاشتباك معًا.

٣. الهجوم (٢٠ دقيقة): تحاول الفرق الحقن المباشر وغير المباشر وتسجّل كل محاولة.

٤. الإصلاح (٢٠ دقيقة): يقترح كل فريق تغيير تصميم واحدًا ويعيد الاختبار.

٥. الختام (٥ دقائق): يكتب الطلاب أكثر نقطة غامضة في المحاضرة وسؤالًا واحدًا، واقرأها قبل الأسبوع القادم.

للنقاش

- أيّ هجوم كان الأصعب منعًا؟
- هل ساعدت تعليمات النظام؟
- ما الذي يجب أن يحتاج موافقة؟

بطاقة الخروج

- سمِّ أداة لن تعطيها أبدًا لتطبيق نموذج لغوي دون موافقة.

جرّبها في محاضرتك القادمة

نفّذ جولة فريق أحمر مدتها عشرون دقيقة على مساعد مقرر في بيئة معزولة ضمن نطاق مكتوب، تسجّل فيها الفرق كل محاولة وتقترح تغيير تصميم واحدًا كان سيمنع أفضل هجوم لديها.

ورقة الحلقة النقاشية، للطلاب

حقن التعليمات وتطبيقات النماذج اللغوية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ٤

الاسم _____ المجموعة _____ التاريخ _____

١ **أيّ تصميم يحدّ الضرر على نحو أفضل إذا حُقن المساعد؟**

○ تعليمات نظام أطول ○ قائمة عبارات محظورة ○ أقل صلاحية وموافقة قبل أي إرسال

٢ **احسب نتائج الفريق الأحمر.**

قبل الدفاعات تنجح 12 من 40 محاولة حقن: _____ %. وبعد أقل صلاحية والموافقة تنجح 2 من 40:

_____ %.

بنك الكلمات: 2، 30، 5، 12

٣ **أيّها يقلّل أثر حقن التعليمات؟ اختر كل ما ينطبق.**

☐ أقل الأدوات والصلاحيات ☐ تعليمات نظام أطول وأشد ☐ معاملة مخرجات النموذج على أنها غير موثوقة

☐ موافقة إنسان على الإرسال أو الحذف

٤ **تمنع تعليمات النظام المكتوبة جيدًا الحقن غير المباشر بموثوقية.**

○ صح ○ خطأ

٥ **طابق كل إجراء وقائي مع الخطر الذي يحدّه.**

أقل صلاحية	• • • •	رسالة تُرسَل دون أن يؤكدها المستخدم
موافقة الإنسان	• • • •	أدوات لا تحتاجها المهمة في متناول نموذج محقون
معاملة المخرجات كغير موثوقة	• • • •	سوء استخدام غير مكتشف
التسجيل	• • • •	وصول كود أو روابط محقونة إلى أنظمة أخرى

الإجابات، لعضو هيئة التدريس

حقن التعليمات وتطبيقات النماذج اللغوية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ٤

١ **أقل صلاحية وموافقة قبل أي إرسال**

يحدّ ما يستطيع النموذج المحقون فعله.

٢ **قبل الدفاعات تنجح 12 من 40 محاولة حقن: 30%. وبعد أقل صلاحية والموافقة تنجح 2 من 40: 5%.**

30% = 12/40 و5% = 2/40. اعرض النسب مع عدد المحاولات.

٣ **أقل الأدوات والصلاحيات، موافقة إنسان على الإرسال أو الحذف، معاملة مخرجات النموذج على أنها غير موثوقة**

يمكن تجاوز التعليمات، أما حدود الأفعال فلا.

٤ **خطأ**

تشترك التعليمات والبيانات في سياق واحد، ويعيد المهاجمون الصياغة حول أي تعليمات.

٥ **أقل صلاحية — أدوات لا تحتاجها المهمة في متناول نموذج محقون**
موافقة الإنسان — رسالة تُرسَل دون أن يؤكدها المستخدم
معاملة المخرجات كغير موثوقة — وصول كود أو روابط محقونة إلى أنظمة أخرى
التسجيل — سوء استخدام غير مكتشف

يزيل مبدأ أقل صلاحية الأدوات التي لا تحتاجها المهمة، وتوقف موافقة الإنسان أي إرسال لم يؤكده أحد، وتمنع معاملة المخرجات كغير موثوقة وصولها إلى أنظمة أخرى دون فحص، ويكشف التسجيل سوء الاستخدام.

✎ **لتفكّر فيه**

إذا اختبر طلابك نظامًا جامعيًا حيًا دون إذن، فأيّ قاعدة سيكسرون، وهل هي مكتوبة؟