خطة المحاضرة، لعضو هيئة التدريس

حقن التعليمات وتطبيقات النماذج اللغوية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ٤

المدة
٦٠ دقيقة

المواد
جهاز عرض أو سبّورة، شرائح المحاضرة وورقة الحلقة النقاشية من الحزمة، هواتف أو حواسيب فيها دَرسي، للمعمل

أهداف التعلّم

- نفسّر حقن التعليمات.
- نصمّم دفاعًا متعدد الطبقات.
- ننفّذ الفريق الأحمر بأمان.

النشاط: فريق أحمر ضمن النطاق

١. التمهيد (٥ دقائق): اعرض التعليمات المخفية في البريد واسأل ماذا سيفعل المساعد.

٢. النطاق (١٠ دقائق): اقرؤوا النطاق وقواعد الاشتباك معًا.

٣. الهجوم (٢٠ دقيقة): تحاول الفرق الحقن المباشر وغير المباشر وتسجّل كل محاولة.

٤. الإصلاح (٢٠ دقيقة): يقترح كل فريق تغيير تصميم واحدًا ويعيد الاختبار.

٥. الختام (٥ دقائق): يكتب الطلاب أكثر نقطة غامضة في المحاضرة وسؤالًا واحدًا، واقرأها قبل الأسبوع القادم.

للنقاش

- أيّ هجوم كان الأصعب منعًا؟
- هل ساعدت تعليمات النظام؟
- ما الذي يجب أن يحتاج موافقة؟

بطاقة الخروج

- سمِّ أداة لن تعطيها أبدًا لتطبيق نموذج لغوي دون موافقة.

جرّبها في محاضرتك القادمة

نفّذ جولة فريق أحمر مدتها عشرون دقيقة على مساعد مقرر في بيئة معزولة ضمن نطاق مكتوب، تسجّل فيها الفرق كل محاولة وتقترح تغيير تصميم واحدًا كان سيمنع أفضل هجوم لديها.

ورقة الحلقة النقاشية، للطلاب

حقن التعليمات وتطبيقات النماذج اللغوية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ٤

الاسم _____ الصف _____ التاريخ _____

١ أيّ تصميم يحدّ الضرر على نحو أفضل إذا حُقن المساعد؟

○ تعليمات نظام أطول ○ قائمة عبارات محظورة ○ أقل صلاحية وموافقة قبل أي إرسال

٢ احسب نتائج الفريق الأحمر.

قبل الدفاعات تنجح 12 من 40 محاولة حقن: _____ %. وبعد أقل صلاحية والموافقة تنجح 2 من 40:

_____ %.

بنك الكلمات: 30، 12، 2، 5

٣ أيّها يقلّل أثر حقن التعليمات؟ اختر كل ما ينطبق.

☐ أقل الأدوات والصلاحيات ☐ موافقة إنسان على الإرسال أو الحذف

☐ معاملة مخرجات النموذج على أنها غير موثوقة ☐ تعليمات نظام أطول وأشد

٤ تمنع تعليمات النظام المكتوبة جيدًا الحقن غير المباشر بموثوقية.

○ صح ○ خطأ

٥ طابق كل ضابط مع الخطر الذي يحدّه.

أقل صلاحية	سوء استخدام غير مكتشف
موافقة الإنسان	وصول كود أو روابط محقونة إلى أنظمة أخرى
معاملة المخرجات كغير موثوقة	أفعال لا رجعة فيها كالإرسال
التسجيل	نموذج محقون يستدعي أدوات قوية

✎ إذا اختبر طلابك نظامًا جامعيًا حيًا دون إذن، فأيّ قاعدة سيكسرون، وهل هي مكتوبة؟