حقن التعليمات وتطبيقات النماذج اللغوية

أمن الذكاء الاصطناعي، الجامعة، المحاضرة ٤

في هذه المحاضرة

- نفسّر حقن التعليمات.
- نصمّم دفاعًا متعدد الطبقات.
- ننفّذ الاختبار الهجومي بأمان.

تذكّر

- التعليمات والبيانات تختلط.
- حدّ نطاق الضرر.
- حدّد النطاق قبل الهجوم.

فريق أحمر ضمن النطاق

١. التمهيد (٥ دقائق): ماذا سيفعل؟

٢. النطاق (١٠ دقائق): القواعد.

٣. الهجوم (٢٠ دقيقة): سجّل.

٤. الإصلاح (٢٠ دقيقة): خفّف.

٥. الختام (٥ دقائق): ورقة الدقيقة الواحدة.

لنتناقش

١. أيّ هجوم كان الأصعب منعًا؟

٢. هل ساعدت تعليمات النظام؟

٣. ما الذي يجب أن يحتاج موافقة؟

بطاقة الخروج

- سمِّ أداة لن تعطيها أبدًا لتطبيق نموذج لغوي دون موافقة.