حزمة المقرر الجامعي

تدريس أمن الذكاء الاصطناعي في الجامعة

مقرر من ١٤ أسبوعًا و٣ ساعات معتمدة في أمن الذكاء الاصطناعي لطلاب السنة الرابعة أو الماجستير في علوم الحاسوب أو علوم البيانات أو الأمن السيبراني. المتطلبات السابقة: تعلّم الآلة وأساسيات الأمن. ترتكز محاضرات «درسي» الأربع على الأسابيع ٣ و٦ و٩ و١١. ولا تُمارَس الهجمات إلا على أنظمة معزولة ضمن قواعد اشتباك مكتوبة.

نواتج التعلّم

١. تحديد نماذج التهديد لأنظمة تعلّم الآلة.

٢. توليد أمثلة عدائية وتقييم الدفاعات بهجمات متكيّفة.

٣. تحليل مخاطر التسميم والأبواب الخلفية في سلاسل توريد البيانات.

٤. قياس تسريب الخصوصية وتطبيق الخصوصية التفاضلية.

٥. تأمين تطبيقات النماذج اللغوية وإجراء فريق أحمر بنطاق محدد.

الخطة الدراسية في ١٤ أسبوعًا

الأسبوع	الموضوع	داخل القاعة وخارجها
١	نماذج التهديد لأنظمة تعلّم الآلة	توقيع قواعد الاشتباك
٢	مراجعة تعلّم الآلة: الخسائر والتدرجات	مجموعة المسائل ١
٣	الأمثلة العدائية وFGSM	المعمل ١: FGSM وPGD
٤	التدريب العدائي والتقييم المتين	تكليف هاجم الدفاع
٥	الهجمات المادية والصندوق الأسود	مجموعة المسائل ٢
٦	تسميم البيانات والأبواب الخلفية	المعمل ٢: ازرع واكتشف
٧	سلسلة توريد البيانات وتتبّع المصدر	امتحان منتصف الفصل
٨	استخراج النماذج وعكسها	مجموعة المسائل ٣
٩	استنتاج العضوية والخصوصية التفاضلية	المعمل ٣: الهجوم وDP-SGD
١٠	التعلّم الموحّد والخصوصية عمليًا	مذكرة الخصوصية
١١	حقن التعليمات وتطبيقات النماذج اللغوية	المعمل ٤: فريق أحمر بنطاق
١٢	تأمين الوكلاء واستخدام الأدوات	بداية المشروع
١٣	الحوكمة: إطار NIST والاستجابة للحوادث	نقطة مراجعة المشروع
١٤	عروض المشاريع والمراجعة	الامتحان النهائي

مخطط شرائح المحاضرات

المحاضرة ١: الأمثلة العدائية

- ملصقات على علامة وقوف
- لماذا تجعل الخطية النماذج هشة
- FGSM وPGD
- التدريب العدائي والتقييم المتكيّف
- النشاط: هاجم ودافع وهاجم مجددًا

المحاضرة ٢: التسميم والأبواب الخلفية

- روبوت محادثة أُوقف في يوم
- الإتاحة والموجّه والباب الخلفي
- لماذا تخفي الدقة النظيفة الأبواب الخلفية
- تتبّع المصدر والتصفية
- النشاط: ارسم سلسلة التوريد

المحاضرة ٣: هجمات الخصوصية

- تقييمات مجهولة أُعيد تحديد أصحابها
- استنتاج العضوية
- الخصوصية التفاضلية وآلية لابلاس
- DP-SGD وميزانية الخصوصية
- النشاط: الاستجابة العشوائية

المحاضرة ٤: حقن التعليمات

- بريد أصدر أوامر
- الحقن المباشر وغير المباشر
- لماذا تفشل الفلاتر
- أقل صلاحية والموافقة والتسجيل
- النشاط: فريق أحمر ضمن النطاق

مجموعة المسائل

١. لمصنّف خطي $w = (0.5, -3, 1, 2)$ والدرجة $w^T x + b = 1.2$ (الصنف الموجب). ما أصغر ميزانية $L\infty$ ε تستطيع عندها FGSM قلب التوقع؟

٢. تعرض ورقة دقة متينة 70% أمام FGSM عند $\varepsilon = 8/255$ ولا هجمات أخرى. اذكر ثلاث نقاط ضعف في هذا التقييم.

٣. زُرع باب خلفي في 0.5% من 40,000 صورة تدريب. الدقة النظيفة 97%، و94% من صور الاختبار المحفَّزة تُصنَّف إلى الهدف. كم صورة سُمّمت، وأيّ رقم يُظهر الهجوم؟

٤. تنشر جامعة ثلاثة أعداد، كلًا منها بضوضاء لابلاس مقياسها 4، وحساسية كل عدد 1. ما ε لكل إصدار، وما الإجمالي حسب التركيب الأساسي؟

٥. يبلغ نموذج دقة تدريب 100% ودقة اختبار 72%. اشرح لماذا هو معرّض لاستنتاج العضوية، واذكر تخفيفين أحدهما بضمان رسمي.

٦. مساعد نموذج لغوي يستطيع قراءة بريد محاضر وإرسال الرسائل. قدّم نموذج تهديد للحقن غير المباشر وثلاثة ضوابط تصميم.

الحلول

١. يمكن أن تنخفض الدرجة بمقدار $\varepsilon\|w\|_1 = 6.5\varepsilon$. ويتطلب القلب $6.5\varepsilon > 1.2$، أي $\varepsilon > 0.185$ (نحو 0.19).

٢. لا هجوم تكراري مثل PGD، ولا هجوم متكيّف مصمَّم للدفاع، ولا فحص لتمويه التدرجات (مثلًا تفوّق هجمات الصندوق الأسود على الأبيض، أو عدم وصول الدقة إلى صفر مع زيادة ε).

٣. 200 صورة. نسبة نجاح الهجوم 94% تُظهره، والدقة النظيفة 97% تخفيه.

٤. المقياس $= \Delta/\varepsilon$، فـ $\varepsilon = 1/4 = 0.25$ لكل منها، والإجمالي $3 \times 0.25 = 0.75$.

٥. الفجوة الكبيرة تعني أنه يتصرف بشكل مختلف مع الأعضاء، ويستطيع المهاجم كشف ذلك من الثقة. ويقلّل التنظيم أو الإيقاف المبكر التسريب، ويعطي DP-SGD حدًا رسميًا.

٦. يرسل غريب تعليمات مخفية يقرؤها المساعد بهدف تسريب البريد. الضوابط: لا إرسال دون موافقة إنسان تعرض المستلمين، وقصر الإرسال على عناوين معروفة، ومعاملة مخرجات النموذج كغير موثوقة وتسجيل كل استدعاءات الأدوات.

ورقة المعمل: المعمل ٤: فريق أحمر ضمن النطاق

الهدف

مهاجمة مساعد مقرر بنموذج لغوي في بيئة معزولة ضمن قواعد مكتوبة، ثم التخفيف وإعادة الاختبار.

الخطوات

١. اقرأ النطاق وقواعد الاشتباك ووقّعها.

٢. حاول الحقن المباشر وسجّل كل محاولة.

٣. ازرع حقنًا غير مباشر في مستندات يسترجعها المساعد.

٤. نفّذ تخفيفًا واحدًا: أقل صلاحية أو موافقة أو معالجة المخرجات.

٥. أعد تشغيل كل المحاولات واعرض نسب النجاح قبل وبعد.

المطلوب تسليمه

تقرير نتائج بالقالب مع النسب قبل وبعد.

حزمة المقرر الجامعي

معيار التقييم

المعيار	ممتاز	جيد	قيد التطور	لم يتحقق بعد
نموذج التهديد	واضح ومبرَّر ومحدد النطاق	هدف وقدرة واضحان	مبهم	غائب
الهجوم والتقييم	هجمات متكيّفة، مع النسب ومقدار عدم اليقين	هجمات متكيّفة	هجمات معيارية فقط	ضعيف أو غير مختبر
التخفيف	منفّذ ومعاد اختباره مع شرح حدوده	منفّذ ومعاد اختباره	مقترح فقط	لا شيء
الأخلاقيات والتقرير	واضح وقابل للتكرار ومسؤول	تقرير واضح	ضمن النطاق وتقرير ضعيف	خارج النطاق

قائمة القراءات

Goodfellow, I. J., Shlens, J., & Szegedy, C. (2015). Explaining and harnessing adversarial examples. ICLR.
FGSM وفرضية الخطية.

Madry, A., Makelov, A., Schmidt, L., Tsipras, D., & Vladu, A. (2018). Towards deep learning models resistant to adversarial attacks. ICLR.
PGD والتدريب العدائي.

Carlini, N., Athalye, A., Papernot, N., Brendel, W., Rauber, J., Tsipras, D., Goodfellow, I., Madry, A., & Kurakin, A. (2019). On evaluating adversarial robustness. arXiv:1902.06705.
كيف تُقيَّم الدفاعات.

Gu, T., Dolan-Gavitt, B., & Garg, S. (2017). BadNets: Identifying vulnerabilities in the machine learning model supply chain. arXiv:1708.06733.
هجمات الأبواب الخلفية.

Shokri, R., Stronati, M., Song, C., & Shmatikov, V. (2017). Membership inference attacks against machine learning models. IEEE Symposium on Security and Privacy.
استنتاج العضوية.

Dwork, C., & Roth, A. (2014). The algorithmic foundations of differential privacy. Foundations and Trends in Theoretical Computer Science, 9(3–4), 211–407.
الخصوصية التفاضلية.

Abadi, M., Chu, A., Goodfellow, I., McMahan, H. B., Mironov, I., Talwar, K., & Zhang, L. (2016). Deep learning with differential privacy. ACM CCS.
DP-SGD.

Greshake, K., Abdelnabi, S., Mishra, S., Endres, C., Holz, T., & Fritz, M. (2023). Not what you've signed up for: Compromising real-world LLM-integrated applications with indirect prompt injection. ACM AISec Workshop.
الحقن غير المباشر للتعليمات.

Vassilev, A., Oprea, A., Fordyce, A., & Anderson, H. (2024). Adversarial machine learning: A taxonomy and terminology of attacks and mitigations (NIST AI 100-2 E2023). NIST.
تصنيف الهجمات.

OWASP Foundation. OWASP Top 10 for Large Language Model Applications. https://genai.owasp.org/
مخاطر تطبيقات النماذج اللغوية.