خطة المراجعة، لعضو هيئة التدريس

تدريس أمن الذكاء الاصطناعي في الجامعة: اختبار الوحدة

أمن الذكاء الاصطناعي، الجامعة، اختبار الوحدة

المدة
٤٠ دقيقة

المواد
جهاز عرض أو سبّورة، وشرائح المحاضرة.

أهداف التعلّم

- الأمثلة العدائية
- التسميم والأبواب الخلفية
- هجمات الخصوصية
- حقن التعليمات

النشاط: مراجعة بالتعلّم من الأقران

١. التصويت (١٠ دقائق): اعرض كل سؤال، ويجيب الطلاب منفردين ويلتزمون بإجابة.
٢. النقاش (١٥ دقيقة): حيث تنقسم الإجابات، يتجادل كل زوجين دقيقتين ثم يصوّتان مرة أخرى.
٣. الشرح (١٠ دقائق): حُلّ الأسئلة التي أخطأ فيها معظم الطلاب، مع عرض الاستدلال خطوة خطوة.
٤. التخطيط (٥ دقائق): دوّن أيّ تصوّر خاطئ ستعود إليه الأسبوع القادم وكيف.

للنقاش

- أيّ تصوّر خاطئ ستستهدف أولًا؟
- أيّ معمل ستضيف؟
- كيف ستبقي الاختبار الهجومي آمنًا؟

بطاقة الخروج

- تغيير في مقرر أمن الذكاء الاصطناعي هذا الفصل الدراسي، وكيف سأعرف أنه نجح.

جرّبها في محاضرتك القادمة

أحضر تكليف هاجم الدفاع ووثيقة نطاق الفريق الأحمر إلى اجتماع القسم القادم للمراجعة.

ورقة الاختبار، للطلاب

تدريس أمن الذكاء الاصطناعي في الجامعة: اختبار الوحدة

أمن الذكاء الاصطناعي، الجامعة، اختبار الوحدة

الاسم _____ المجموعة _____ التاريخ _____

١ تحرّك FGSM كل خاصية بمقدار ε في اتجاه

○ إشارة عشوائية ○ إشارة تدرج الخسارة ○ سالب المدخل

٢ احسب حد التغيير.

w = (5, -2, 1) و ε = 0.1: يمكن أن تتغير الدرجة بمقدار _____ .

بنك الكلمات: 0.5، 0.8، 0.1، 0.4

٣ يُظهر النموذج ذو الباب الخلفي عادة دقة نظيفة منخفضة.

○ صح ○ خطأ

٤ أقوى دليل على متانة دفاع:

○ دقة نظيفة عالية ○ تفشل FGSM أمامه ○ يصمد أمام هجمات متكيّفة ضمن نموذج تهديد محدد

٥ اضبط الضوضاء.

الحساسية 1 و ε = 0.25: مقياس لابلاس = _____ .

بنك الكلمات: 2، 4، 0.25

٦ أيّها يزيد خطر استنتاج العضوية؟ اختر كل ما ينطبق.

☐ نشر درجات الثقة كاملة ☐ فجوة كبيرة بين التدريب والاختبار ☐ التدريب بـ DP-SGD

٧ التعليمات المخفية في صفحة ويب مسترجعة

○ حقن مباشر للتعليمات ○ حقن غير مباشر للتعليمات ○ تسميم البيانات

٨ طابق كل هجوم مع مرحلته.

التسميم	• • • •	مدخل الاستدلال
المثال العدائي	• • • •	مخرجات النموذج
استنتاج العضوية	• • • •	التدريب

٩ نشر العدّ نفسه مرتين، بضوضاء جديدة عند ε = 0.5 في كل مرة، يستهلك من ميزانية الخصوصية قدر ما يستهلكه إصدار واحد عند ε = 1.

○ صح ○ خطأ

١٠ أفضل طريقة لتقييم تمرين فريق أحمر طلابي:

○ عدد مرات كسر الحماية ○ الهجمات على أنظمة حية ○ جودة النتائج والتخفيفات ضمن النطاق

الإجابات، لعضو هيئة التدريس

تدريس أمن الذكاء الاصطناعي في الجامعة: اختبار الوحدة

أمن الذكاء الاصطناعي، الجامعة، اختبار الوحدة

١ إشارة تدرج الخسارة

يزيد الخسارة بأسرع ما يمكن لكل خاصية.

٢ $w = (5, -2, 1)$ و$\varepsilon = 0.1$: يمكن أن تتغير الدرجة بمقدار 0.8.

$0.8 = (1 + 2 + 5) \times 0.1 = \varepsilon \times \Sigma|w|$. والمجموع بالإشارة 4 كان سيعطي 0.4، وأكبر وزن وحده 0.5: كل خاصية تتحرك، فتُحسب كل $|w_i|$.

٣ خطأ

تحافظ الأبواب الخلفية على الدقة النظيفة.

٤ يصمد أمام هجمات متكيّفة ضمن نموذج تهديد محدد

هاجم الدفاع نفسه.

٥ الحساسية 1 و$\varepsilon = 0.25$: مقياس لابلاس = 4.

المقياس $= 1 / 0.25 = 4$: Δ/ε كلما صغرت ε زادت الضوضاء.

٦ فجوة كبيرة بين التدريب والاختبار، نشر درجات الثقة كاملة

يقلّل DP-SGD الخطر.

٧ حقن غير مباشر للتعليمات

يصل الهجوم عبر المحتوى.

٨ التسميم — التدريب
المثال العدائي — مدخل الاستدلال
استنتاج العضوية — مخرجات النموذج

تحتاج كل مرحلة إجراءاتها الوقائية.

٩ صح

تكرار الاستعلام ليس مجانيًا: كل إصدار بضوضاء جديدة يستهلك $\varepsilon = 0.5$، ويجمعهما التركيب الأساسي إلى $\varepsilon = 1$.

١٠ جودة النتائج والتخفيفات ضمن النطاق

كافئ التحليل لا الضرر.